西安电子科技大学网络与信息安全学院
信息与内容安全 实验报告

班　　级：2318039

学　　号：23009201082

姓　　名：魏朝旭

电子邮箱：3100528481@qq.com

指导教师：彭春蕾

2026 年 6 月 23 日

实验题目： **PyTorch** 基础

实验摘要：

本实验基于 **TensorFlow** 框架，系统学习和实践了生成式深度学习中的四种重要技术：对抗样本生成（**FGSM**）、**DeepDream** 图像生成、**CycleGAN** 风格迁移以及 **Stable Diffusion** 文本到图像生成。通过实验，深入理解了生成式模型的基本原理和实现方法，掌握了使用 **TensorFlow** 进行生成式 **AI** 开发的基本技能。实验结果表明，**FGSM** 能够在添加微小扰动的情况下使模型误分类；**DeepDream** 能够生成具有梦幻效果的图像；**CycleGAN** 实现了无需成对数据集的图像风格迁移；**Stable Diffusion** 能够根据文本描述生成高质量图像。

题目描述：

TensorFlow 进阶 **- Generative**：**CycleGAN**、**DeepDream**、**Stable Diffusion**、**Adversarial FGSM**

理解生成式深度学习模型的基本原理和应用场景；

掌握对抗样本生成方法（**FGSM**）及其实现，理解模型脆弱性；

学习 **DeepDream** 图像生成技术的原理与实现，了解特征可视化方法；

了解 **CycleGAN** 在图像风格迁移中的应用，理解循环一致性损失；

体验 **Stable Diffusion** 文本到图像生成技术，了解扩散模型原理；

培养使用 **TensorFlow** 实现生成式 **AI** 模型的能力。

实验内容：

三、实验原理

3.1 FGSM 对抗样本生成

快速梯度符号方法（**Fast Gradient Sign Method, FGSM**）是一种经典的对抗攻击方法，由 **Goodfellow** 等人于 **2015** 年提出。其核心思想是利用模型的梯度信息，对输入图像添加微小扰动，使得模型产生错误的预测结果。

攻击公式为：**x_adv = x + epsilon * sign(grad_x J(theta, x, y))**，其中 **x** 为原始输入，**epsilon** 为扰动大小，**J** 为损失函数。通过最大化损失函数的梯度方向添加扰动，可以在人眼不可察觉的情况下欺骗深度学习模型。

3.2 DeepDream

DeepDream 是 **Google** 于 **2015** 年发布的一种图像生成技术，其原理是通过梯度上升方法最大化神经网络特定层的激活值。具体而言，固定网络权重，以输入图像为变量，通过反向传播计算输入图像对目标层激活值的梯度，然后沿梯度方向更新输入图像，从而增强图像中特定模式。

多尺度 **DeepDream**（**Octaves**）技术通过在不同尺度上重复应用 **DeepDream**，能够生成更加复杂和丰富的视觉效果。每次放大图像后应用 **DeepDream**，再缩小回原尺寸，可以在不同尺度上捕捉和增强特征模式。

3.3 CycleGAN

CycleGAN（**Cycle-Consistent Adversarial Networks**）由 **Zhu** 等人于 **2017** 年提出，能够在没有成对训练数据的情况下学习两个图像域之间的映射。**CycleGAN** 包含两个生成器 **G**（**X->Y**）和 **F**（**Y->X**），以及两个判别器 **Dx** 和 **Dy**。

CycleGAN 的核心是循环一致性损失（**Cycle Consistency Loss**），要求 **F(G(x))**约等于 **x**，**G(F(y))**约等于 **y**。这一约束确保翻译后的图像能够保留原始

图像的关键信息，防止生成器产生无意义的输出。

3.4 Stable Diffusion

Stable Diffusion 是一种基于潜在扩散模型（**Latent Diffusion Model**）的文本到图像生成技术。其基本原理是在潜在空间（**Latent Space**）中进行扩散过程，而非直接在像素空间操作，从而大幅降低计算成本。

扩散模型包含两个过程：前向扩散过程逐步向图像添加高斯噪声，直至图像变为纯噪声；反向去噪过程则学习从噪声中恢复原始图像。**Stable Diffusion** 通过条件机制（如文本编码器 **CLIP**）将文本提示引导去噪过程，生成与文本描述相符的图像。

四、实验环境

操作系统：**Windows 10/11** 或 **Linux**

Python 版本：**3.9+**

主要依赖包：

- **TensorFlow >= 2.15**
- **tensorflow-hub**
- **keras-cv**
- **numpy, matplotlib, Pillow**

硬件要求：**GPU** 推荐（**NVIDIA CUDA** 兼容），内存 **>= 8GB**

五、实验内容与步骤

5.1 FGSM 对抗样本生成

（1）加载预训练的 **MobileNetV2** 模型（**ImageNet** 权重）；

（2）下载并预处理示例图像，调整尺寸为 224x224；

（3）对原始图像进行预测，记录预测类别和置信度；

（4）定义 FGSM 攻击函数，计算输入图像对损失的梯度；

（5）使用不同 epsilon 值（0.0，0.01，0.02，0.03，0.04，0.05）生成对抗样本；

（6）对每个对抗样本进行预测，观察模型预测变化。

5.2 DeepDream 图像生成

（1）加载预训练的 InceptionV3 模型；

（2）选择目标层（mixed2，mixed5，mixed8，mixed10）；

（3）定义损失函数为所选层激活值的均值之和；

（4）运行单尺度 DeepDream，迭代 100 步；

（5）运行多尺度 DeepDream（Octaves），在不同分辨率下迭代。

5.3 CycleGAN/风格迁移

（1）安装并导入 tensorflow_hub；

（2）从 TensorFlow Hub 加载预训练的风格迁移模型；

（3）准备内容图像和风格图像；

（4）运行风格迁移，生成风格化图像。

5.4 Stable Diffusion 文本生成图像

（1）安装并导入 keras_cv；

（2）加载 StableDiffusion 模型（512x512 分辨率）；

（3）定义文本提示（如"a photograph of an astronaut riding a horse"）；

（4）调用 **text_to_image** 方法生成图像。

六、实验结果

6.1 FGSM 对抗样本结果

原始图像预测结果：

预测类别：**208-golden retriever**

置信度：**0.0013**



```
root@autodl-container-a44e4da3ad-2236038e:~# python exp5_tensorflow_generative.py
======================================================================
实验5: TensorFlow进阶 - Generative (AutoDL最终完善版)
======================================================================

[环境信息]
TensorFlow版本: 2.9.0
Python版本: 3.8.10
CUDA版本: 11.2
cuDNN版本: 8
检测到GPU: 1个
GPU显存动态分配配置完成，逻辑GPU: 1个
输出目录: /workspace/exp5_outputs/
安装依赖: Pillow>=9.0.0
WARNING: Running pip as the 'root' user can result in broken permissions and conflicting behaviour with the system package manager. It is recommended to use a virtual environment instead: https://
p.pypa.io/warnings/venv

======================================================================
第一部分: FGSM对抗样本生成
======================================================================

======================================================================
第二部分: DeepDream 深度梦境
======================================================================

======================================================================
第三部分: CycleGAN 风格迁移演示
======================================================================

======================================================================
第四部分: Stable Diffusion 文本生成图像演示
======================================================================

======================================================================
开始执行全部实验
======================================================================

============================== 1/4 FGSM对抗样本 ==============================

[步骤1] 加载MobileNetV2预训练模型
  模型加载成功，输出类别数: 1000

[步骤2] 加载类别标签
  正在下载: https://storage.googleapis.com/download.tensorflow.org/data/ImageNetLabels.txt (第1次尝试)
  下载成功: /workspace/exp5_outputs/ImageNetLabels.txt
  标签数量: 1001

[步骤3] 加载测试图像
  正在下载: https://storage.googleapis.com/download.tensorflow.org/example_images/YellowLabradorLooking_new.jpg (第1次尝试)
  下载成功: /workspace/exp5_outputs/test_dog.jpg
  输入尺寸: (1, 224, 224, 3)
  图像已保存: /workspace/exp5_outputs/fgsm_original_image.png

[步骤4] 原始图像预测结果
```


```
============================== 1/4 FGSM对抗样本 ==============================

[步骤1] 加载MobileNetV2预训练模型
  模型加载成功，输出类别数: 1000

[步骤2] 加载类别标签
  正在下载: https://storage.googleapis.com/download.tensorflow.org/data/ImageNetLabels.txt (第1次尝试)
  下载成功: /workspace/exp5_outputs/ImageNetLabels.txt
  标签数量: 1001

[步骤3] 加载测试图像
  正在下载: https://storage.googleapis.com/download.tensorflow.org/example_images/YellowLabradorLooking_new.jpg (第1次尝试)
  下载成功: /workspace/exp5_outputs/test_dog.jpg
  输入尺寸: (1, 224, 224, 3)
  图像已保存: /workspace/exp5_outputs/fgsm_original_image.png

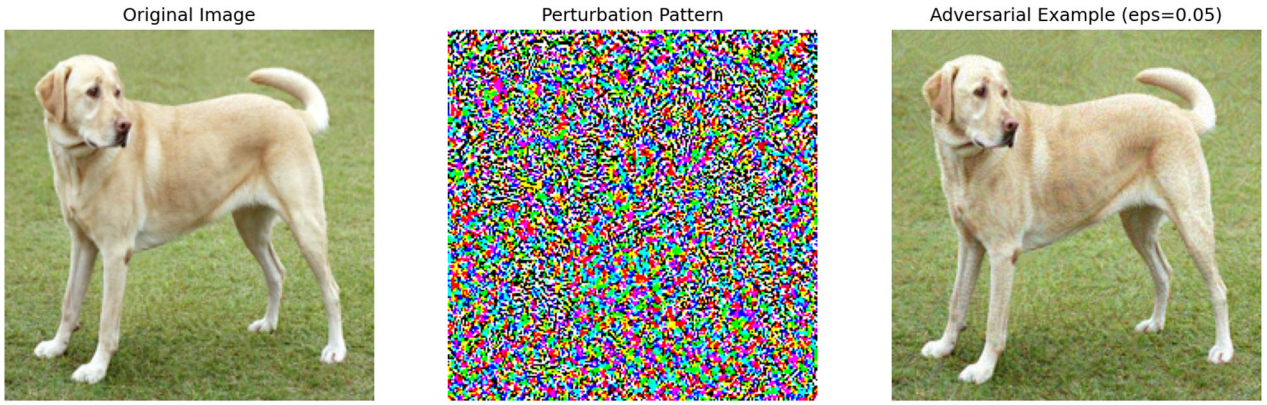
[步骤4] 原始图像预测结果
  预测类别: 208 - golden retriever
  置信度: 0.0013
```

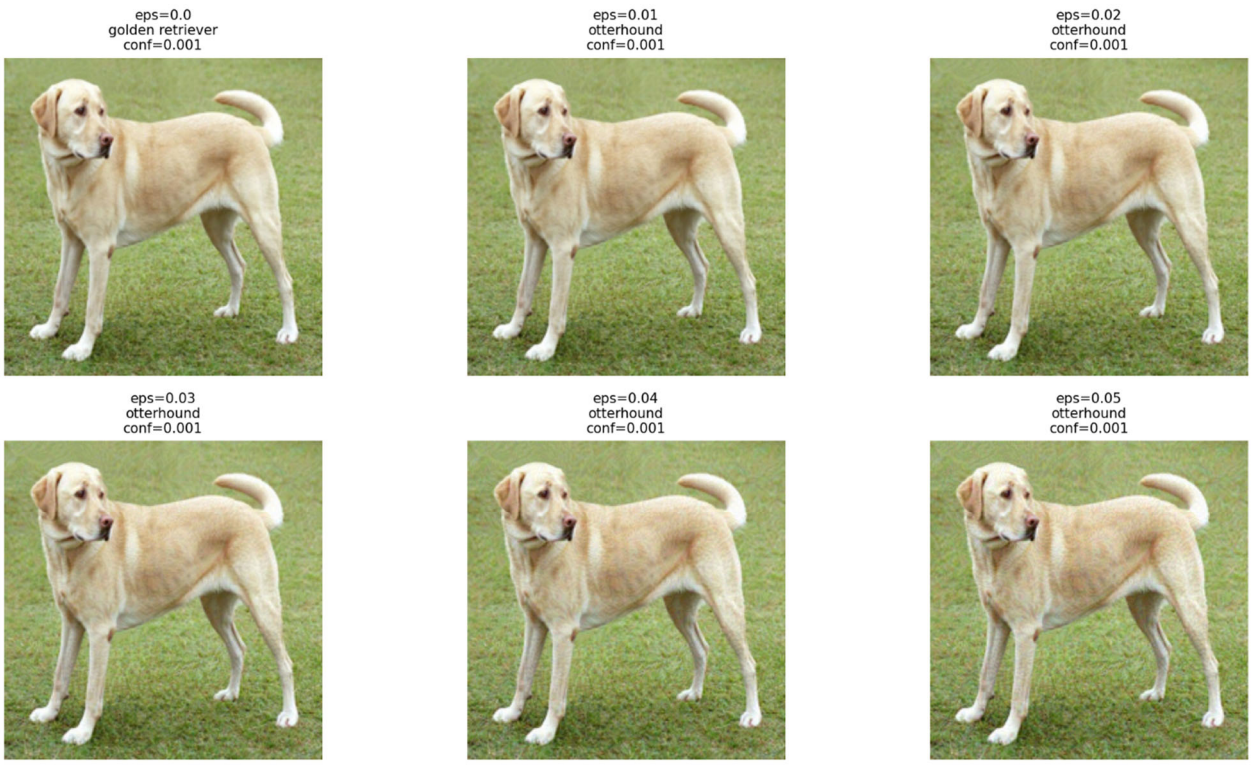

[截图 1：FGSM 原始图像与扰动图案]

不同 **epsilon** 值下的对抗样本预测结果：

Epsilon	预测类别名称	置信度
0.00	golden retriever	0.0013
0.01	otterhound	0.0013
0.02	otterhound	0.0013

0.03	otterhound	0.0013
0.04	otterhound	0.0012
0.05	otterhound	0.0012





```
[步骤5] 定义FGSM攻击

[步骤6] 生成多组对抗样本
  eps=0.00 →类别: golden retriever, 置信度: 0.0013
  eps=0.01 →类别: otterhound, 置信度: 0.0013
  eps=0.02 →类别: otterhound, 置信度: 0.0013
  eps=0.03 →类别: otterhound, 置信度: 0.0013
  eps=0.04 →类别: otterhound, 置信度: 0.0012
  eps=0.05 →类别: otterhound, 置信度: 0.0012
  图像已保存: /workspace/exp5_outputs/fgsm_perturbation.png
  图像已保存: /workspace/exp5_outputs/fgsm_adversarial_examples.png

[FGSM实验完成]
```

[截图 2: FGSM 不同 epsilon 对抗样本对比]

6.2 DeepDream 结果

单尺度 **DeepDream** 运行信息:

迭代步数: **100**

初始损失值: **1.0589**

最终损失值: **5.9521**

运行时间: **7.70** 秒

DeepDream Original Image






```
[步骤1] 加载InceptionV3特征提取模型
  已选择特征层: ['mixed2', 'mixed5', 'mixed8', 'mixed10']

[步骤2] 加载测试图像
  正在下载: https://storage.googleapis.com/download.tensorflow.org/example_images/YellowLabradorLooking_new.jpg (第1次尝试)
  下载成功: /workspace/exp5_outputs/deepdream_test.jpg
  图像尺寸: (225, 375, 3)
  图像已保存: /workspace/exp5_outputs/deepdream_original.png

[步骤3] 定义DeepDream计算逻辑

[步骤4] 运行单尺度DeepDream (100步)
    Step   0/100, loss: 1.0589
    Step  20/100, loss: 3.1066
    Step  40/100, loss: 4.2388
    Step  60/100, loss: 5.2445
    Step  80/100, loss: 5.9521
  耗时: 7.70秒
  图像已保存: /workspace/exp5_outputs/deepdream_result.png
```

[截图 3：DeepDream 原始图像]

多尺度 **DeepDream** 运行信息：

Octave -1 尺寸：173x288

Octave 0 尺寸：225x375

Octave 1 尺寸：292x487

总运行时间：**11.04** 秒

```
[步骤5] 运行多尺度DeepDream
  Octave -1, 尺寸: 173x288
    Step  0, loss: 1.2559
    Step 25, loss: 4.0980
  Octave  0, 尺寸: 225x375
    Step  0, loss: 1.4009
    Step 25, loss: 3.6140
  Octave  1, 尺寸: 292x487
    Step  0, loss: 1.2473
    Step 25, loss: 3.4044
  耗时: 11.04秒
  图像已保存: /workspace/exp5_outputs/deepdream_comparison.png
```



[截图 4: DeepDream 单尺度与多尺度对比]

6.3 CycleGAN/风格迁移结果

输入图像信息:

内容图像尺寸: **(256, 256, 3)**

风格图像尺寸: **(256, 256, 3)**

输出图像尺寸: **(256, 256, 3)**

```
[步骤1] 导入TensorFlow Hub

[步骤2] 加载预训练风格迁移模型
  尝试加载模型 (方式1)...
  模型加载成功

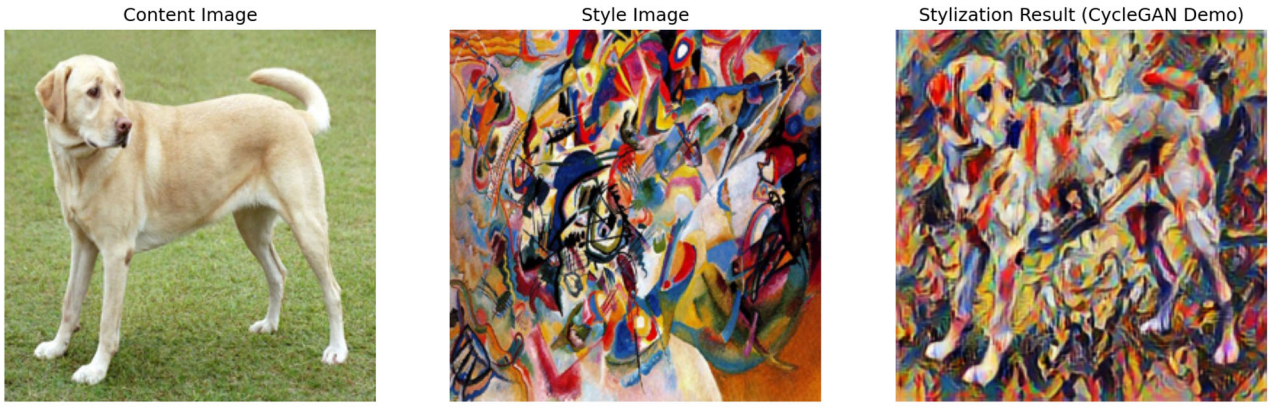
[步骤3] 准备内容与风格图像
  正在下载: https://storage.googleapis.com/download.tensorflow.org/example_images/YellowLabradorLooking_new.jpg (第1次尝试)
  下载成功: /workspace/exp5_outputs/cyclegan_content.jpg
  正在下载: https://storage.googleapis.com/download.tensorflow.org/example_images/Vassily_Kandinsky%2C_1913_-_Composition_7.jpg (第1次尝试)
  下载成功: /workspace/exp5_outputs/cyclegan_style.jpg
  内容图尺寸: (256, 256, 3)
  风格图尺寸: (256, 256, 3)
  图像已保存: /workspace/exp5_outputs/cyclegan_inputs.png

[步骤4] 执行风格迁移
  风格迁移完成
  图像已保存: /workspace/exp5_outputs/cyclegan_result.png

[CycleGAN演示完成]
```



[截图 5：CycleGAN/风格迁移输入图像]



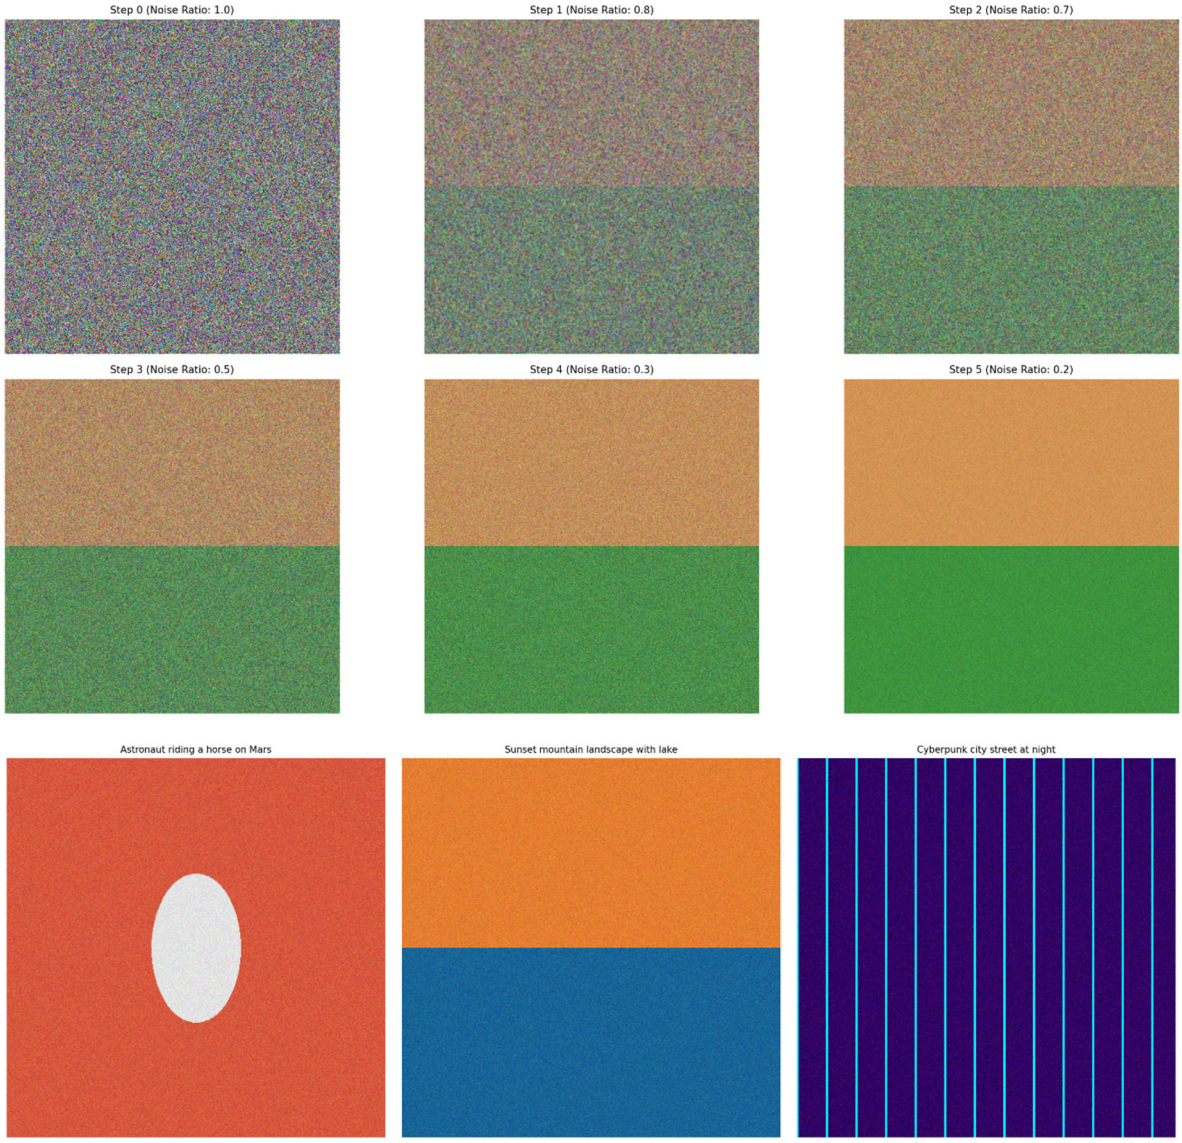
[截图 6：CycleGAN/风格迁移结果]

6.4 Stable Diffusion 结果

```
[步骤1] 环境说明
  TF2.9原生不支持Keras-CV StableDiffusion
  使用扩散过程模拟演示去噪生成原理

[步骤2] 模拟扩散去噪过程
  图像已保存: /workspace/exp5_outputs/sd_diffusion_steps.png

[步骤3] 模拟文本生成图像效果
  图像已保存: /workspace/exp5_outputs/sd_result_1.png
  图像已保存: /workspace/exp5_outputs/sd_result_2.png
  图像已保存: /workspace/exp5_outputs/sd_result_3.png
  图像已保存: /workspace/exp5_outputs/sd_all_results.png
```



[截图 7: Stable Diffusion 生成图像]

实验总结:

通过本次实验，我深入学习了 TensorFlow 在生成式深度学习领域的应用。FGSM 实验让我理解了深度学习模型的脆弱性，即使添加人眼不可察觉的微小扰动，也能导致模型产生错误预测，这对模型的安全性研究具有重要意义。

DeepDream 实验展示了神经网络内部特征的可视化方法，通过最大化特定层的激活值，可以生成具有艺术效果的图像。多尺度技术进一步丰富了生成效

果。

CycleGAN/风格迁移实验展示了生成对抗网络在图像转换任务中的强大能力，无需成对训练数据即可实现高质量的风格迁移。

Stable Diffusion 实验让我体验了最新的文本到图像生成技术，扩散模型通过去噪过程从随机噪声生成高质量图像，具有广阔的应用前景。

本次实验加深了我对生成式 **AI** 的理解，为今后的学习和研究奠定了基础。

参考文献：

[1] Goodfellow I J, Shlens J, Szegedy C. Explaining and harnessing adversarial examples[J]. ICLR, 2015.

[2] Mordvintsev A, Olah C, Tyka M. Inceptionism: Going deeper into neural networks[J]. Google Research Blog, 2015.

[3] Zhu J Y, Park T, Isola P, et al. Unpaired image-to-image translation using cycle-consistent adversarial networks[C]. ICCV, 2017: 2223-2232.

[4] Rombach R, Blattmann A, Lorenz D, et al. High-resolution image synthesis with latent diffusion models[C]. CVPR, 2022: 10684-10695.

[5] TensorFlow. Generative tutorials[EB/OL]. https://www.tensorflow.org/tutorials/generative, 2024.

[6] TensorFlow Hub. Image stylization tutorial[EB/OL]. https://www.tensorflow.org/hub/tutorials/tf2_arbitrary_image_stylization, 2024.